Impact de la sparsité sur l'informativité de la transcriptomique single cell

Immersion en hôpital

Mayeul Lambert Céline Liu

April 26, 2026

MVA

Introduction

Contexte d'étude : l'Endocrinologie

- Étude des **glandes surrénales**, situées au-dessus des reins.
- Focus sur les tumeurs de la **corticosurrénale**.

Objet d'Etude : Le Transcriptome

- ADN $\rightarrow$ ARN $\rightarrow$ Protéines.
- Le **transcriptome** correspond à l'ensemble des ARN exprimés dans une cellule.
- Il reflète l'**activité fonctionnelle** de la cellule à un instant donné.

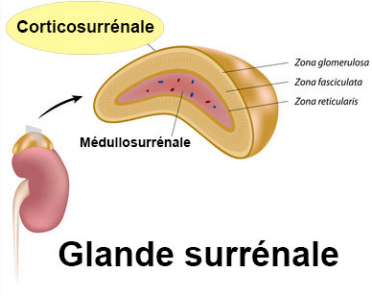

Étudier le Transcriptome : 3 échelles d'analyse

- **Bulk RNA-seq**
  - Séquençage de l'ensemble du tissu mélangé.
  - Mesure une moyenne globale : **incapable de distinguer** les différents types cellulaires présents.

- **Single-cell RNA-seq (scRNA-seq)**
  - Résolution à l'échelle de la cellule individuelle.
  - Données sparses et bruitées.

- **Transcriptomique spatiale**
  - Cartographie *in situ* préservant la topologie tissulaire.
  - **Profondeur de lecture limitée** (très faible efficacité de capture).

Jeu de données et Problématique

Tumeurs de la corticosurrénale annotées à 3 échelles :

1. **Clinique** (*Tumor Type*)
2. **Macroscopique** (*Cell Types*)
3. **Microscopique** (*Microenvironment States*)

Réduire la profondeur de lecture diminue les coûts mais augmente drastiquement la **sparsité**.

→ **Jusqu'à quel seuil peut-on dégrader le signal sans perdre l'identification des sous-types cellulaires ?**

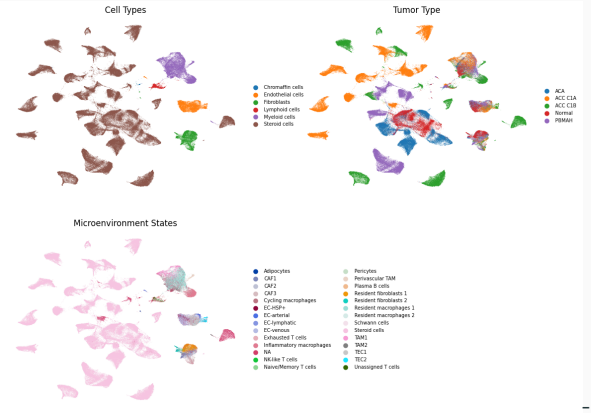

Jeu de données

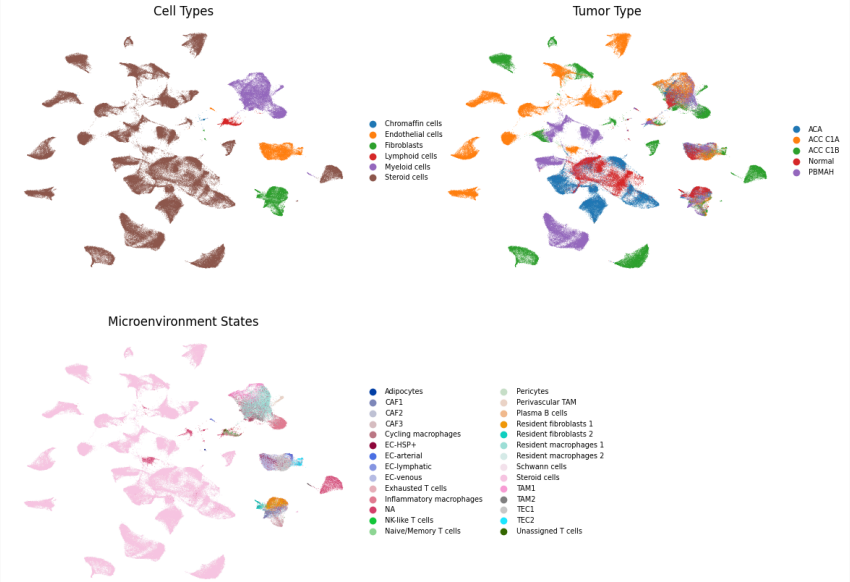

Jeu de données

On considère un jeu de données *single-cell* $D \in \mathbb{R}^{N \times G}$, où N est le nombre de cellules et G le nombre de gènes. Chaque entrée correspond au **nombre de reads** (comptes bruts) d'un gène dans une cellule.

$$N = 168\,927 \quad ; \quad G = 16\,638$$

Stéroïdes	133 501
Myéloïdes	**16 698**
Endothéliales	**8 540**
Fibroblastes	**7 942**
Lymphoïdes	2054
Chromaffines	192

Table 1: Répartition des types cellulaires. En gras, les types d'intérêt.

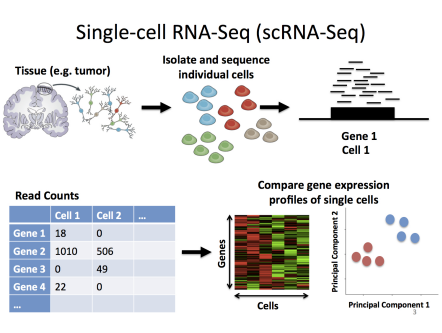

Source : Stephanie Hicks

Théorie

Soit λ_{ij} le nombre réel de transcrits du gène j dans la cellule i. Ce niveau d'expression fluctue selon l'état biologique de la cellule.

$$\lambda_{ij} \sim \text{Gamma}\left(\theta_j, \frac{\mu_{ij}}{\theta_j}\right)$$

où μ_{ij} est l'espérance d'expression et θ_j la dispersion propre au gène j.

Soit X_{ij} le nombre de transcrits observés (*counts*) après séquençage. Dans un scénario de capture parfaite, nous aurions :

$$X_{ij} \mid \lambda_{ij} \sim \text{Poisson}(\lambda_{ij}) \quad \Longrightarrow \quad X_{ij} \sim \text{NB}(\mu_{ij}, \theta_j)$$

Cependant, les limites technologiques induisent une perte d'information :

$$\boxed{X_{ij} \mid \lambda_{ij} \sim \text{Poisson}(\epsilon_i \cdot \lambda_{ij}) \implies X_{ij} \sim \text{NB}(\epsilon_i \cdot \mu_{ij}, \theta_j)}$$

où $0 < \epsilon_i \leq 1$ désigne **l'efficacité de capture** *pour la cellule i.*

Simulation de la sparsité

En théorie sparsité $\nearrow \Leftrightarrow \epsilon_j \searrow$

En pratique nous n'avons pas accès qu'à un sample $X = (X_{ij})_{i \in [N], j \in [G]}$ qui a été construit à partir de $(\epsilon_j, \mu_{ij}, \theta_i)$ qui sont inconnues.

Or, sous-échantillonner (*subsampling*) X de manière binomiale avec $p \in (0, 1)$ revient à obtenir un sample $\tilde{X}$:

$$\tilde{X}_{ij} \mid \lambda_{ij} \sim \text{Poisson}(p \cdot \epsilon_j \cdot \lambda_{ij}) \quad \text{et} \quad \tilde{X}_{ij} \sim NB(p \cdot \epsilon_j \cdot \mu_{ij}, \theta_i)$$ **Thinning de Poisson**

$\rightarrow$ Pour simuler $\epsilon_j \searrow$, il nous suffit de $p_{start} = 1 \searrow p_{end} \sim 0$

Thinning (de Poisson)

Thinning de Poisson Pour chaque cellule, on tire un *read* avec une probabilité $p \Leftrightarrow$ tirage multinomiale pour chaque cellule selon la distribution empirique.

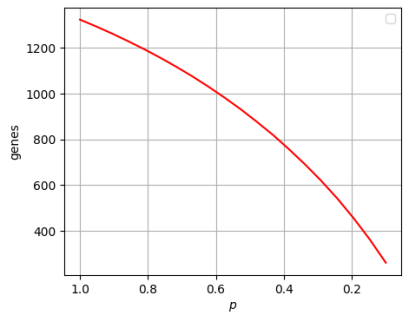

$$X_{ij} \sim NB(\epsilon_j \cdot \mu_{ij}, \theta_{ij})$$
$$\log(\mu_{ij}) = \log(\epsilon_j) + \log(\mu_{ij})$$

Figure 1: Nombre de gènes moyens par niveau de sparsité. Pour une technologie de single cells, on se référence plutôt aux nombres moyens de gènes détectés par cellule.

Jeu de données - Transformation SCT

En transcriptomie, on distingue deux types de sparsités

- la sparsité **biologique** (la non-présence d'un gène au sein d'une cellule),
- la sparsité **technique** (la non-détection d'un gène faiblement exprimé au sein du transcriptome d'une cellule) $\rightarrow$ l'objet de notre étude.

La transformation SCT est une transformation du jeu de données bruts qui a pour but de corriger cet effet.

$$(SCT) \rightarrow \log(\mu_{ij}) = \beta_{i,0} + \beta_{i,1} \log_{10}(m_j), \quad m_j \approx \epsilon_j \cdot \sum_i \mu_{ij}$$

$$r_{ij} = \frac{X_{ij} - \hat{\mu}_{ij}}{\sqrt{\mu_{ij} + \frac{\hat{\mu}_{ij}^2}{\hat{\theta}_i}}} \qquad \text{Résidus de Pearson}$$

m_j: la profondeur de lecture / le nombre de counts bruts de la cellule j, μ_{ij}: l'espérance (counts bruts) du gène i dans la cellule j, θ_{ij}: sa dispersion (une cellule n'est pas un réservoir fixe d'exemplaires de gènes).

Jeu de données - Transformation SCT

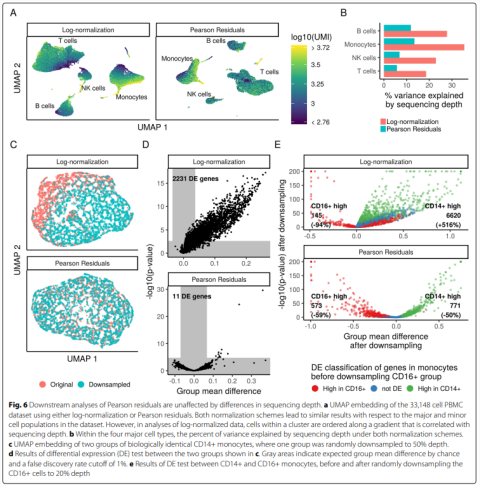

Fig. 6 Downstream analyses of Pearson residuals are unaffected by differences in sequencing depth. **a** UMAP embedding of the 33,148 cell PBMC dataset using either log-normalization or Pearson residuals. Both normalization schemes lead to similar results with respect to the major and minor cell populations in the dataset. However, in analyses of log-normalized data, cells within a cluster are ordered along a gradient that is correlated with sequencing depth. **b** Within the four major cell types, the percent of variance explained by sequencing depth under both normalization schemes. **c** UMAP embedding of two groups of biologically identical CD14+ monocytes, where one group was randomly downsampled to 50% depth. **d** Results of differential expression (DE) test between the two groups shown in **c**. Gray areas indicate expected group mean difference by chance and a false discovery rate cutoff of 1%. **e** Results of DE test between CD14+ and CD16+ monocytes, before and after randomly downsampling the CD16+ cells to 20% depth

Figure 2: Effets de la transformation SCT (Hafemeister & Satija, 2019)

Méthodes de clustering

On dispose de plusieurs méthodes de partionnement (ou *clustering*),

- K-Means / Gaussian Mixtures Model ✗ $\rightarrow$ la donnée ne correspond aux hypothèses de ces algorithmes (blobs réguliers)
- Clustering hiérarchique ✓
- **Louvain / Leiden** ✓$\rightarrow$ privilégiées par la communauté

Clustering de Louvain / Leiden

Ces deux méthodes servent au partitionnement d'un graphe en le scindant en **communautés** (sous-ensembles de noeuds très connectés) en maximisant la **modularité** du graphe.

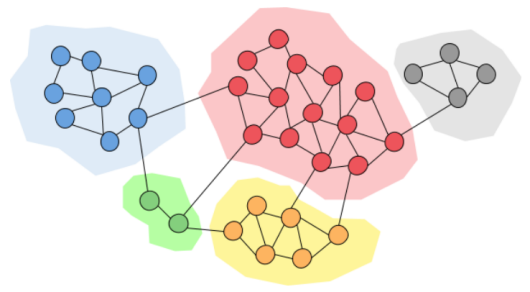

Figure 3: Un exemple de partitionnement issu de l'algorithme de Leiden.

Pipeline de clustering

Algorithm 1 Pipeline de clustering

Initialisation :

k = nombre de voisins

resolution = paramètre de clustering

d = nombre de composantes PCA

$p \in (0, 1)$ = niveau de sparsité

1: Sélection du niveau de sparsité p

2: Normalisation SCT des données

3: Calcul de la représentation PCA sur les données SCT avec d composantes

4: Construction du graphe des k plus proches voisins (distance euclidienne dans l'espace PCA)

5: Calcul des matrices de distances et de similarité

6: Application du clustering de Leiden avec la résolution *resolution*

Ensure: Partition des données en clusters

Pipeline de clustering

La *résolution* de clustering de Leiden est un paramètre qui pénalise les clusters selon leur taille.

- Une **grande résolution** $\rightarrow$ pénalise les grands clusters et les **fragmente en petits**.
- Une **petite résolution** $\rightarrow$ pénalise les petits clusters et les **fusionne en grands**.

Pour le choix de la *résolution*:

- Maximiser le score **ARI** entre les labels Leiden et les labels *ground truth*.
- Recherche par **Optuna** ou **Golden section search** mais il faut pouvoir suffisamment lisser le bruit pour obtenir une fonction unimodale.

Évaluation du clustering (1/3) : Objectifs

Notre but est de savoir si nous sommes encore capable d'identifier les sous-types cellulaires, sans connaissance a priori (i.e clustering).

Il nous faut des métriques pour pouvoir évaluer l'issue de notre clustering et savoir s'il est en accord avec notre objectif.

Cependant, en changeant le niveau de sparsité on bouleverse la distribution des points,

- Les clusters peuvent **s'éclater** et augmenter le niveau de sous-granularité déjà existant.
- Au contraire, l'effondrement de l'information peut **fusionner** plusieurs clusters.

→ Une métrique qui est **indépendante de la structure topologique des données**.

Exemple de clustering par Leiden

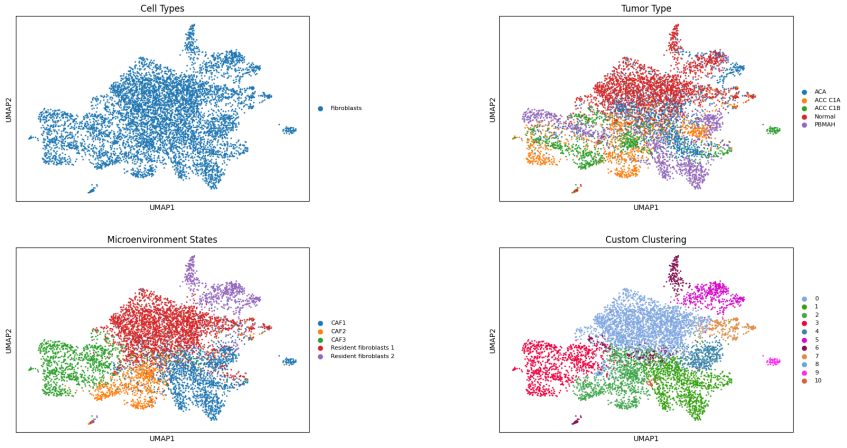

Figure 4: Un exemple de clustering par Leiden sur les cellules fibroblastiques. On détecte plus clusters que prévu mais sont-ils tous "faux" pour autant ?

Évaluation du clustering (2/3) : Théorie de l'information

L'évaluation repose sur la distribution conditionnelle des classes d'origine C sachant les clusters prédits K.

- **Homogénéité (h)** : Un cluster est-il pur ? (Ne contient qu'une classe d'origine)

$$h = 1 - \frac{H(C|K)}{H(C)}$$

- **Complétude (c)** : Une classe est-elle bien regroupée ? (Tous ses membres sont dans le même cluster)

$$c = 1 - \frac{H(K|C)}{H(K)}$$

- **v-Measure (v)** Moyenne harmonique de l'homogénéité et de la complétude

Évaluation du clustering (3/3) : Approche combinatoire

L'évaluation repose sur l'accord entre les partitions pour l'ensemble des $\binom{n}{2}$ paires de cellules distinctes.

- **Rand Index (RI)** : Proportion de paires concordantes.

$$RI = \frac{a+b}{\binom{n}{2}}$$

où a (resp. b) est le nombre de paires dans la même classe (resp. classes diff.) et le même cluster (resp. clusters diff.).

- **Adjusted Rand Index (ARI)** : Correction du RI face au hasard.

$$ARI = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]}$$

$\rightarrow$ **Propriété :** $\mathbb{E}[ARI] = 0$ sous l'hypothèse d'un étiquetage aléatoire (modèle hypergéométrique).

Démarche

Clustering de Leiden $\rightarrow$ Contrôle de k du graphe k-Neighbors.

- Plus k est **petit** et plus notre clustering se base sur **l'information de petits voisinages**.
- Plus k est **grand** et plus notre clustering se base sur des **relations globales** et sur la **structure du jeu de données entier**.

Notre approche,

- Un score d'**homogénéité faible** pour $\mathbf{k_0}$ **petit** $\rightarrow$ il sera **faible** $\forall \mathbf{k} > \mathbf{k_0}$, et vice-versa.
- A l'inverse, un score d'**homogénéité faible** pour $\mathbf{k}^*$ **grand** $\rightarrow$ il **peut être fort** $\forall \mathbf{k} < \mathbf{k}^*$.

$\rightarrow$ **k petit établit un seuil critique à partir duquel toute démarche est inespéré !**

$\rightarrow$ **k grand établit un seuil critique à partir duquel on ne pourra plus obtenir un clustering de même qualité que le ground truth.**

Attendus

On note r_k^h le seuil critique d'homogénéité à partir duquel on considère qu'il y a un effondrement de l'information pour un graphe de k voisins.
On s'attend à observer,

- Pour h fixé, $k \nearrow \Rightarrow \; r_k^h \searrow$.
- Que certains sous-types soient la cause de l'effondrement.

Résultats - Evolution du score selon k

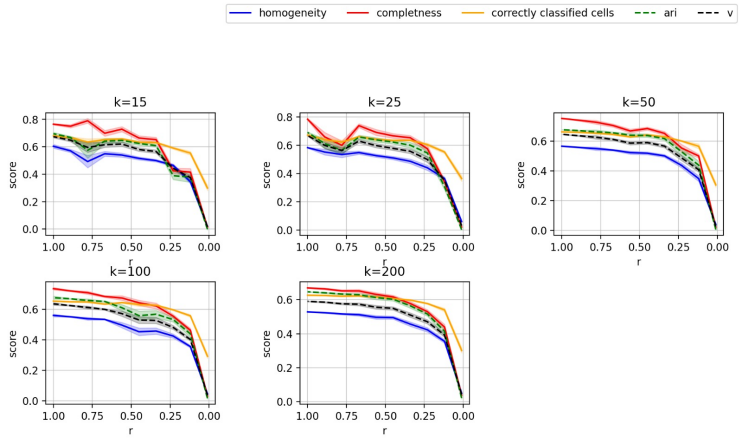

Figure 5: Analyse de l'impact de k sur les cellules myéloïdes sur 25 runs

Résultats - Evolution du score selon k

Type	$k = 15$	$k = 25$	$k = 50$	$k = 100$	$k = 200$
Endothéliales	0.06 / 166	0.07 / 190	0.21 / 483	0.25 / 553	0.46 / 853
Fibroblasts	0.13 / 327	0.25 / 553	0.19 / 446	0.24 / 536	0.77 / 1160
Myeloids	0.19 / 446	0.25 / 553	0.20 / 465	0.19 / 446	0.22 / 501

Table 2: Seuils critiques à $h = 0.4$ en niveau de sparsité et en nombre de gènes par type de cellules (estimés sur 25 runs).

Résultats - Impact des sous-types

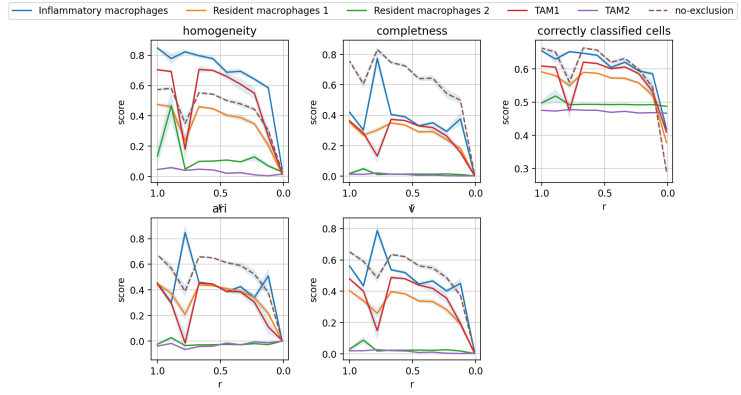

Figure 6: Analyse de l'impact de chaque sous type cellulaire sur les cellules myéloïdes pour $k = 20$ sur 25 runs

Résultats - Impact des sous-types

Type & Sous-Type	**Seuil critique ($h = 0.4$)**
Fibroblasts	
CAF1	0.80 / 1311
CAF2	1.00 / 1484
CAF3	0.05 / 147
Resident fibroblasts 1	0.27 / 626
Resident fibroblasts 2	0.08 / 226
Myeloid	
Inflammatory macrophages	0.25 / 574
Residents macrophages 1	0.45 / 877
Residents macrophages 2	1.00 / 1389
TAM1	0.32 / 691
TAM2	1.00 / 1389

Table 3: Seuils critiques par type et sous-type de cellules en niveau de sparsité et en nombre de gènes pour $k = 20$ sur 25 runs

Résultats - Gènes discriminants

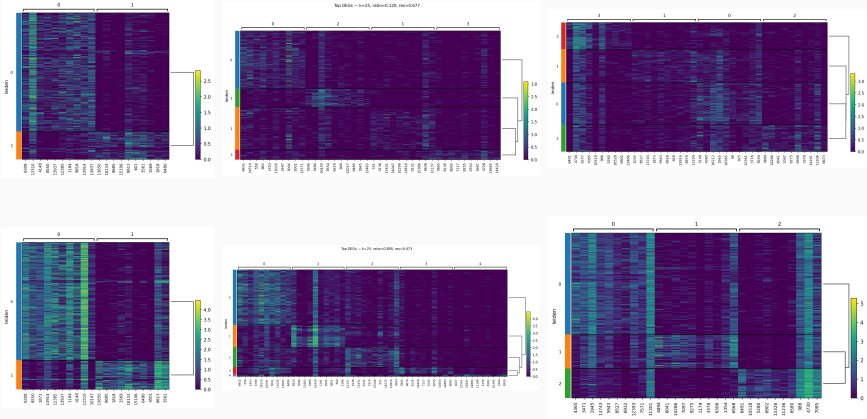

Figure 7: Score de discrimination de chaque gène par cellule. De gauche à droite : Endothéliales, Fibroblasts, Myéloïdes.

Résultats - Evolution du score selon k

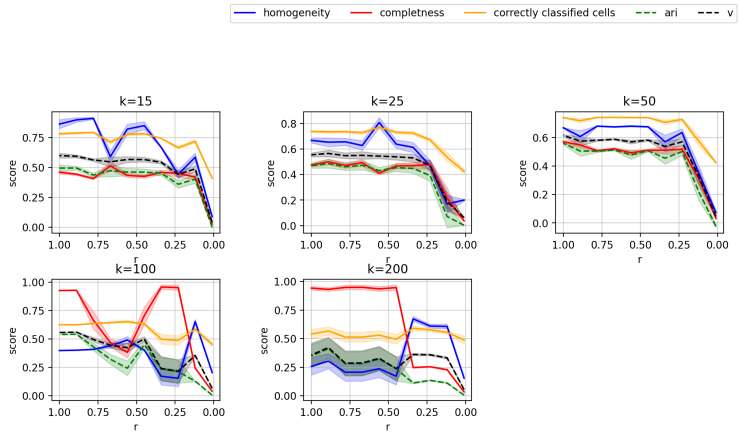

Figure 8: Analyse de l'impact de k sur chaque type cellulaire sur 25 runs

Résultats - Impact des types

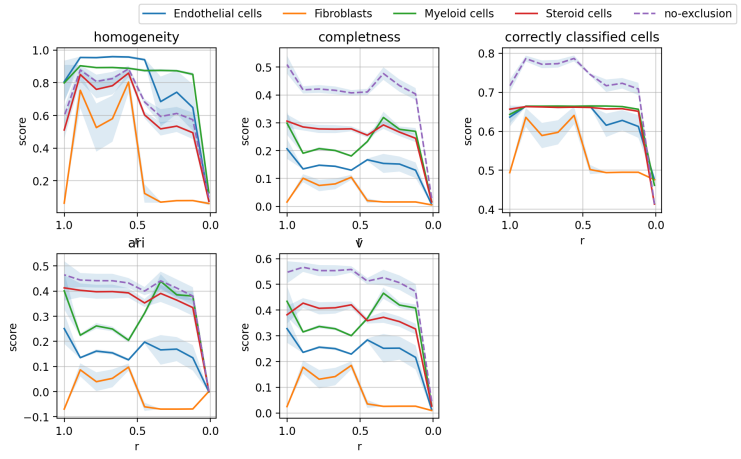

Figure 9: Analyse de l'impact de chaque type cellulaire pour $k = 20$ sur 25 runs

Résultats - Impact des types

Type	$k = 20$
Stéroïdes	$>> 0.25$
Endothéliales	$>> \ 0.25 \sim 0$
Fibroblasts	0.55
Myeloids	$>> \ 0.25 \sim 0$

Table 4: Seuils critiques à $h = 0.4$ en niveau de sparsité et en nombre de gènes par type de cellules (estimés sur 25 runs).

Difficultés rencontrées

- Temps de calcul : répétition de thinning + clustering de leiden
- Coût en mémoire : taille du jeu de données originales, taille du graphe k-neighbors et PCA.
- Discrétisation insuffisante : Les contraintes computationnelles nous obligent à considérer un nombre faible de points $\rightarrow$ grosse approximation des seuils.
- Analyses de la causalité : quelle sous-type est la cause de l'effondrement ? Qui se mélange avec qui ?

Ouverture

Notre étude reste rudimentaire

- Clustering de Leiden : l'informativité du dataset peut être **encodé** différemment.
- Métriques basiques : nos métriques se contentent de comparer des labels
- Echantillonnages du nombre de cellules (2k)

Nous aurions pu,

- **Variational Auto-Encoder**: l'espace latent encoderait l'informativité du dataset. Construction d'un score de reconstruction ? Entraînement à la classification ? Masked Auto-Encoder ?
- Utiliser différentes techniques de clustering et les mixer, comme ce que font en pratique les biostatisticiens.

Merci !